SPRAWOZDANIE
Zajęcia: Nauka o danych I
Prowadzący: prof. dr hab. Vasyl Martsenyuk

SPRAWOZDANIE Zajęcia: Nauka o danych I Prowadzący: prof. dr hab. Vasyl Martsenyuk Laboratorium Nr 1 Data 25.02.2025 Temat: Wprowadzenie do narzędzi i środowiska pracy w analizie danych Wariant 16	Krzysztof Świerczek Informatyka II stopień, stacjonarne, 1semestr, gr. A

1. Polecenie:
16. Low- and Middle-Income Country Drinking Water and Sanitation Fa cilities Access Geospatial Estimates 2000-2017 http://ghdx.healthd ata.org/record/ihme-data/lmic-wash-access-geospatial-estim ates-2000-2017
2. Github:
https://github.com/Krzycho165/STUDIA

In [1]:
```
# 1. Ładowanie biblioteki Pandas
import pandas as pd
```

In [2]:
```
# 2. Tworzenie ramki danych ze słownika
dane_slownik = {
    "Kraj": ["USA", "Kanada", "Meksyk"],
    "Ludność (mln)": [331, 38, 128],
    "PKB (bln USD)": [23, 2, 1.3]
}

ramka_danych_slownik = pd.DataFrame(dane_slownik)

print("Ramka danych utworzona ze słownika:")
print(ramka_danych_slownik)
```

```
Ramka danych utworzona ze słownika:
     Kraj  Ludność (mln)  PKB (bln USD)
0     USA            331           23.0
1  Kanada             38            2.0
2  Meksyk            128            1.3
```

In [5]:
```
# 3. Wczytanie danych z pliku CSV
plik_csv = "IHME_USA_RISK_SPENDING_2016_Y2020M09D29.csv"
ramka_danych_csv = pd.read_csv(plik_csv)

# Wyświetlenie pierwszych wierszy ramki danych
print("Ramka danych wczytana z pliku CSV:")
print(ramka_danych_csv.head())
```

```
Ramka danych wczytana z pliku CSV:
   location_id             location_name  year  sex_id   sex  age_group_id  \
0          102  United States of America  2016       1  Male           158
1          102  United States of America  2016       1  Male           170
2          102  United States of America  2016       1  Male           171
3          102  United States of America  2016       1  Male           154
4          102  United States of America  2016       1  Male            22

  age_group_name acause  cause_name  risk_id  \
0      <20 years   _all  All causes       82
1       20 to 44   _all  All causes       82
2       45 to 64   _all  All causes       82
3        65 plus   _all  All causes       82
4       All Ages   _all  All causes       82

                                  risk_name          metric        mean  \
0  Unsafe water, sanitation, and handwashing  2016 US Dollar   52.810750
1  Unsafe water, sanitation, and handwashing  2016 US Dollar   48.000244
2  Unsafe water, sanitation, and handwashing  2016 US Dollar   69.765933
3  Unsafe water, sanitation, and handwashing  2016 US Dollar   88.960404
4  Unsafe water, sanitation, and handwashing  2016 US Dollar  259.537331

        lower       upper
0   34.776353   76.466271
1   31.644490   70.893323
2   45.764417  101.797946
3   59.168652  128.091201
4  171.226033  375.015989
```

In [6]:
```
# 4. Tworzenie ramki danych z listy list
dane_lista = [
    ["Nowy Jork", 8419600, "USA"],
    ["Toronto", 2930000, "Kanada"],
    ["Meksyk", 9209944, "Meksyk"]
]

ramka_danych_lista = pd.DataFrame(dane_lista, columns=["Miasto", "Ludność", "Kra

print("\nRamka danych utworzona z listy list:")
print(ramka_danych_lista)
```

```
Ramka danych utworzona z listy list:
      Miasto  Ludność    Kraj
0  Nowy Jork  8419600     USA
1    Toronto  2930000  Kanada
2     Meksyk  9209944  Meksyk
```

In [7]:
```
# 5. Transponowanie (zamiana kolumn z wierszami)
ramka_danych_lista_transponowana = ramka_danych_lista.T

print("\nRamka danych po transponowaniu:")
print(ramka_danych_lista_transponowana)
```

```
Ramka danych po transponowaniu:
                0        1        2
Miasto   Nowy Jork  Toronto   Meksyk
Ludność    8419600  2930000  9209944
Kraj           USA   Kanada   Meksyk
```

In [8]:
```
# 6. Wyświetlenie pierwszych 10 wierszy ramki danych
print("\nPierwsze 10 wierszy ramki danych:")
print(ramka_danych_csv.head(10))
```

```
Pierwsze 10 wierszy ramki danych:
   location_id             location_name  year  sex_id     sex  age_group_id  \
0          102  United States of America  2016       1    Male           158
1          102  United States of America  2016       1    Male           170
2          102  United States of America  2016       1    Male           171
3          102  United States of America  2016       1    Male           154
4          102  United States of America  2016       1    Male            22
5          102  United States of America  2016       2  Female           158
6          102  United States of America  2016       2  Female           170
7          102  United States of America  2016       2  Female           171
8          102  United States of America  2016       2  Female           154
9          102  United States of America  2016       2  Female            22

  age_group_name acause  cause_name  risk_id  \
0      <20 years   _all  All causes       82
1       20 to 44   _all  All causes       82
2       45 to 64   _all  All causes       82
3        65 plus   _all  All causes       82
4       All Ages   _all  All causes       82
5      <20 years   _all  All causes       82
6       20 to 44   _all  All causes       82
7       45 to 64   _all  All causes       82
8        65 plus   _all  All causes       82
9       All Ages   _all  All causes       82

                                risk_name          metric        mean  \
0  Unsafe water, sanitation, and handwashing  2016 US Dollar   52.810750
1  Unsafe water, sanitation, and handwashing  2016 US Dollar   48.000244
2  Unsafe water, sanitation, and handwashing  2016 US Dollar   69.765933
3  Unsafe water, sanitation, and handwashing  2016 US Dollar   88.960404
4  Unsafe water, sanitation, and handwashing  2016 US Dollar  259.537331
5  Unsafe water, sanitation, and handwashing  2016 US Dollar   50.183598
6  Unsafe water, sanitation, and handwashing  2016 US Dollar   68.050031
7  Unsafe water, sanitation, and handwashing  2016 US Dollar  101.383728
8  Unsafe water, sanitation, and handwashing  2016 US Dollar  143.750803
9  Unsafe water, sanitation, and handwashing  2016 US Dollar  363.368161

        lower       upper
0   34.776353   76.466271
1   31.644490   70.893323
2   45.764417  101.797946
3   59.168652  128.091201
4  171.226033  375.015989
5   33.315353   74.363904
6   44.128452  100.984476
7   66.731697  150.924915
8   94.584101  213.790479
9  240.982485  533.239066
```

In [9]:
```python
# 7. Wyświetlenie ostatnich 10 wierszy ramki danych
print("\nOstatnie 10 wierszy ramki danych:")
print(ramka_danych_csv.tail(10))
```

```
Ostatnie 10 wierszy ramki danych:
      location_id             location_name  year  sex_id     sex  \
1231          102  United States of America  2016       2  Female
1232          102  United States of America  2016       2  Female
1233          102  United States of America  2016       2  Female
1234          102  United States of America  2016       2  Female
1235          102  United States of America  2016       2  Female
1236          102  United States of America  2016       3    Both
1237          102  United States of America  2016       3    Both
1238          102  United States of America  2016       3    Both
1239          102  United States of America  2016       3    Both
1240          102  United States of America  2016       3    Both

      age_group_id age_group_name acause                  cause_name  \
1231           158      <20 years     rf  Expenditure on risk factors
1232           170       20 to 44     rf  Expenditure on risk factors
1233           171       45 to 64     rf  Expenditure on risk factors
1234           154        65 plus     rf  Expenditure on risk factors
1235            22       All Ages     rf  Expenditure on risk factors
1236           158      <20 years     rf  Expenditure on risk factors
1237           170       20 to 44     rf  Expenditure on risk factors
1238           171       45 to 64     rf  Expenditure on risk factors
1239           154        65 plus     rf  Expenditure on risk factors
1240            22       All Ages     rf  Expenditure on risk factors

      risk_id             risk_name          metric         mean        lower  \
1231      108  High body-mass index  2016 US Dollar   101.248712    80.521641
1232      108  High body-mass index  2016 US Dollar  2867.831645  2015.340713
1233      108  High body-mass index  2016 US Dollar  3036.836793  2104.770152
1234      108  High body-mass index  2016 US Dollar  1025.951678   697.331792
1235      108  High body-mass index  2016 US Dollar  7031.868829  5216.248151
1236      108  High body-mass index  2016 US Dollar   186.043387   142.143526
1237      108  High body-mass index  2016 US Dollar  3697.662630  2626.047083
1238      108  High body-mass index  2016 US Dollar  4403.916422  3083.734761
1239      108  High body-mass index  2016 US Dollar  1457.018966  1104.520225
1240      108  High body-mass index  2016 US Dollar  9744.641404  7222.418431

            upper
1231    126.900237
1232   3745.282634
1233   3961.429497
1234   1909.052706
1235   8948.681094
1236    232.865620
1237   4824.208117
1238   5662.947080
1239   2292.252672
1240  12418.772000
```

In [10]:
```python
# 8. Wyświetlenie informacji o ramce danych
print("\nInformacje o ramce danych:")
print(ramka_danych_csv.info())
```

```
Informacje o ramce danych:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1241 entries, 0 to 1240
Data columns (total 15 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   location_id     1241 non-null   int64
 1   location_name   1241 non-null   object
 2   year            1241 non-null   int64
 3   sex_id          1241 non-null   int64
 4   sex             1241 non-null   object
 5   age_group_id    1241 non-null   int64
 6   age_group_name  1241 non-null   object
 7   acause          1241 non-null   object
 8   cause_name      1241 non-null   object
 9   risk_id         1241 non-null   int64
 10  risk_name       1241 non-null   object
 11  metric          1241 non-null   object
 12  mean            1241 non-null   float64
 13  lower           1241 non-null   float64
 14  upper           1241 non-null   float64
dtypes: float64(3), int64(5), object(7)
memory usage: 145.6+ KB
None
```

In [12]:
```
# 9. Wyświetlenie liczby wierszy i kolumn
print("\nLiczba wierszy i kolumn w ramce danych:")
print(ramka_danych_csv.shape)  # Zwraca (liczba_wierszy, liczba_kolumn)
```

```
Liczba wierszy i kolumn w ramce danych:
(1241, 15)
```

In [13]:
```
# 10. Wyświetlenie informacji statystycznej o kolumnach liczbowych
print("\nStatystyki dla kolumn liczbowych:")
print(ramka_danych_csv.describe())
```

```
Statystyki dla kolumn liczbowych:
       location_id    year       sex_id  age_group_id      risk_id  \
count       1241.0  1241.0  1241.000000   1241.000000  1241.000000
mean         102.0  2016.0     2.020145    132.887188   129.024174
std            0.0     0.0     0.812452     59.017044    73.481341
min          102.0  2016.0     1.000000     22.000000    82.000000
25%          102.0  2016.0     1.000000    154.000000    98.000000
50%          102.0  2016.0     2.000000    158.000000   105.000000
75%          102.0  2016.0     3.000000    170.000000   125.000000
max          102.0  2016.0     3.000000    171.000000   381.000000

                mean          lower          upper
count    1241.000000    1241.000000    1241.000000
mean     7523.642696    5972.186569    9227.098980
std     18443.451439   15681.094146   21316.739752
min         0.058442   -4401.524592       0.105215
25%       275.378150     129.072794     421.882542
50%      1372.476758     821.243571    2097.737090
75%      5763.893904    4033.397743    7515.218944
max    238503.405500  178217.189400  291573.753200
```

In [14]:
```
# 11. Wyświetlenie informacji statystycznej o kolumnach kategorycznych
print("\nStatystyki dla kolumn kategorycznych:")
print(ramka_danych_csv.describe(include=['object']))
```

```
Statystyki dla kolumn kategorycznych:
                  location_name     sex age_group_name acause  cause_name  \
count                      1241    1241           1241   1241        1241
unique                        1       3              5     13          13
top     United States of America  Female       20 to 44   _all  All causes
freq                       1241     422            271    268         268

          risk_name          metric
count          1241            1241
unique           19               1
top     Alcohol use  2016 US Dollar
freq            150            1241
```

In [15]:
```python
# 12. Usunięcie brakujących wartości w ramce danych
ramka_danych_csv = ramka_danych_csv.dropna()

print("\nBrakujące wartości zostały usunięte. Aktualny kształt ramki danych:")
print(ramka_danych_csv.shape)  # Sprawdzenie liczby wierszy i kolumn po usunięci
```

```
Brakujące wartości zostały usunięte. Aktualny kształt ramki danych:
(1241, 15)
```

In [16]:
```python
# 13. Wybór wierszy i kolumn po nazwach oraz indeksach

# Sprawdzenie dostępnych kolumn
print("\nDostępne kolumny w ramce danych:")
print(ramka_danych_csv.columns)

# Wybór kolumn po nazwach (przykładowe kolumny)
kolumny_do_wyboru = ["location_name", "mean"]
kolumny_do_wyboru = [col for col in kolumny_do_wyboru if col in ramka_danych_csv

print("\nWybór kolumn po nazwach:")
print(ramka_danych_csv.loc[0:5, kolumny_do_wyboru])  # Pierwsze 6 wierszy

# Wybór kolumn po indeksach
print("\nWybór kolumn po indeksach:")
print(ramka_danych_csv.iloc[0:5, 1:3])  #
```

```
Dostępne kolumny w ramce danych:
Index(['location_id', 'location_name', 'year', 'sex_id', 'sex', 'age_group_id',
       'age_group_name', 'acause', 'cause_name', 'risk_id', 'risk_name',
       'metric', 'mean', 'lower', 'upper'],
      dtype='object')

Wybór kolumn po nazwach:
              location_name        mean
0  United States of America   52.810750
1  United States of America   48.000244
2  United States of America   69.765933
3  United States of America   88.960404
4  United States of America  259.537331
5  United States of America   50.183598

Wybór kolumn po indeksach:
              location_name  year
0  United States of America  2016
1  United States of America  2016
2  United States of America  2016
3  United States of America  2016
4  United States of America  2016
```

In [17]:
```python
# 14. Wybór wierszy na podstawie określonej wartości kolumny

# Sprawdzenie, czy kolumna "risk_name" istnieje w danych
kolumna_filtrowana = "risk_name"
wartosc_filtrowana = "Alcohol use"  # Możesz zmienić na inną wartość występującą

if kolumna_filtrowana in ramka_danych_csv.columns:
    print(f"\nWiersze, gdzie {kolumna_filtrowana} to '{wartosc_filtrowana}':")
    print(ramka_danych_csv[ramka_danych_csv[kolumna_filtrowana] == wartosc_filtr
else:
    print(f"\nBłąd: Kolumna '{kolumna_filtrowana}' nie istnieje w ramce danych."
```

```
Wiersze, gdzie risk_name to 'Alcohol use':
      location_id             location_name  year  sex_id   sex  age_group_id  \
75            102  United States of America  2016       1  Male           158
76            102  United States of America  2016       1  Male           170
77            102  United States of America  2016       1  Male           171
78            102  United States of America  2016       1  Male           154
79            102  United States of America  2016       1  Male            22
...           ...                       ...   ...     ...   ...           ...
1089          102  United States of America  2016       3  Both           158
1090          102  United States of America  2016       3  Both           170
1091          102  United States of America  2016       3  Both           171
1092          102  United States of America  2016       3  Both           154
1093          102  United States of America  2016       3  Both            22

     age_group_name  acause          cause_name  risk_id    risk_name  \
75         <20 years    _all         All causes      102  Alcohol use
76          20 to 44    _all         All causes      102  Alcohol use
77          45 to 64    _all         All causes      102  Alcohol use
78           65 plus    _all         All causes      102  Alcohol use
79          All Ages    _all         All causes      102  Alcohol use
...              ...     ...                ...      ...          ...
1089       <20 years  digest  Digestive diseases      102  Alcohol use
1090        20 to 44  digest  Digestive diseases      102  Alcohol use
1091        45 to 64  digest  Digestive diseases      102  Alcohol use
1092         65 plus  digest  Digestive diseases      102  Alcohol use
1093        All Ages  digest  Digestive diseases      102  Alcohol use

                metric          mean         lower         upper
75    2016 US Dollar    809.896112    564.217748   1136.318912
76    2016 US Dollar   9805.336756   7776.821020  12054.894010
77    2016 US Dollar  12964.862750   8391.647387  18270.423670
78    2016 US Dollar   5421.192741   1730.902323   9576.866836
79    2016 US Dollar  29001.288360  19289.247540  39797.832630
...              ...           ...           ...           ...
1089  2016 US Dollar     22.821660     10.088865     41.226727
1090  2016 US Dollar    905.703730    522.197991   1308.987930
1091  2016 US Dollar    916.635307    392.092905   1478.297508
1092  2016 US Dollar    277.444986     31.625331    540.776131
1093  2016 US Dollar   2122.605684    987.873947   3282.622546

[150 rows x 15 columns]
```

In [19]:

```python
# 15. Wybór wierszy spełniających kilka warunków jednocześnie

# Sprawdzamy, czy kolumny istnieją
kolumna1 = "risk_name"
wartosc1 = "Alcohol use"
kolumna2 = "year"
wartosc2 = 2016

if kolumna1 in ramka_danych_csv.columns and kolumna2 in ramka_danych_csv.columns
    print(f"\nWiersze, gdzie {kolumna1} to '{wartosc1}' i {kolumna2} to {wartosc
    print(ramka_danych_csv[(ramka_danych_csv[kolumna1] == wartosc1) & (ramka_dan
else:
    print(f"\nBłąd: Jedna z kolumn '{kolumna1}' lub '{kolumna2}' nie istnieje w
```

```
Wiersze, gdzie risk_name to 'Alcohol use' i year to 2016:
      location_id             location_name  year  sex_id   sex  age_group_id  \
75            102  United States of America  2016       1  Male           158
76            102  United States of America  2016       1  Male           170
77            102  United States of America  2016       1  Male           171
78            102  United States of America  2016       1  Male           154
79            102  United States of America  2016       1  Male            22
...           ...                       ...   ...     ...   ...           ...
1089          102  United States of America  2016       3  Both           158
1090          102  United States of America  2016       3  Both           170
1091          102  United States of America  2016       3  Both           171
1092          102  United States of America  2016       3  Both           154
1093          102  United States of America  2016       3  Both            22

     age_group_name  acause          cause_name  risk_id    risk_name  \
75         <20 years    _all         All causes      102  Alcohol use
76          20 to 44    _all         All causes      102  Alcohol use
77          45 to 64    _all         All causes      102  Alcohol use
78           65 plus    _all         All causes      102  Alcohol use
79          All Ages    _all         All causes      102  Alcohol use
...              ...     ...                ...      ...          ...
1089       <20 years  digest  Digestive diseases      102  Alcohol use
1090        20 to 44  digest  Digestive diseases      102  Alcohol use
1091        45 to 64  digest  Digestive diseases      102  Alcohol use
1092         65 plus  digest  Digestive diseases      102  Alcohol use
1093        All Ages  digest  Digestive diseases      102  Alcohol use

                metric          mean         lower         upper
75    2016 US Dollar    809.896112    564.217748   1136.318912
76    2016 US Dollar   9805.336756   7776.821020  12054.894010
77    2016 US Dollar  12964.862750   8391.647387  18270.423670
78    2016 US Dollar   5421.192741   1730.902323   9576.866836
79    2016 US Dollar  29001.288360  19289.247540  39797.832630
...              ...           ...           ...           ...
1089  2016 US Dollar     22.821660     10.088865     41.226727
1090  2016 US Dollar    905.703730    522.197991   1308.987930
1091  2016 US Dollar    916.635307    392.092905   1478.297508
1092  2016 US Dollar    277.444986     31.625331    540.776131
1093  2016 US Dollar   2122.605684    987.873947   3282.622546

[150 rows x 15 columns]
```

In [20]:

```python
# 16. Wybór wierszy, gdzie kolumna kategoryczna zawiera określone słowo

# Kolumna do filtrowania i słowo kluczowe
kolumna_filtrowana = "risk_name"
slowo_kluczowe = "Tobacco"  # Możesz zmienić na inne słowo

# Sprawdzenie, czy kolumna istnieje
if kolumna_filtrowana in ramka_danych_csv.columns:
    print(f"\nWiersze, gdzie kolumna '{kolumna_filtrowana}' zawiera słowo '{slow
    print(ramka_danych_csv[ramka_danych_csv[kolumna_filtrowana].str.contains(slc
else:
    print(f"\nBłąd: Kolumna '{kolumna_filtrowana}' nie istnieje w ramce danych."
```

```
Wiersze, gdzie kolumna 'risk_name' zawiera słowo 'Tobacco':
      location_id            location_name  year  sex_id     sex  \
60            102  United States of America  2016       1    Male
61            102  United States of America  2016       1    Male
62            102  United States of America  2016       1    Male
63            102  United States of America  2016       1    Male
64            102  United States of America  2016       1    Male
...           ...                       ...   ...     ...     ...
1176          102  United States of America  2016       2  Female
1177          102  United States of America  2016       3    Both
1178          102  United States of America  2016       3    Both
1179          102  United States of America  2016       3    Both
1180          102  United States of America  2016       3    Both

      age_group_id age_group_name acause                    cause_name  \
60             158      <20 years   _all                    All causes
61             170       20 to 44   _all                    All causes
62             171       45 to 64   _all                    All causes
63             154        65 plus   _all                    All causes
64              22       All Ages   _all                    All causes
...            ...            ...    ...                           ...
1176            22       All Ages   resp  Chronic respiratory diseases
1177           170       20 to 44   resp  Chronic respiratory diseases
1178           171       45 to 64   resp  Chronic respiratory diseases
1179           154        65 plus   resp  Chronic respiratory diseases
1180            22       All Ages   resp  Chronic respiratory diseases

      risk_id risk_name          metric          mean         lower  \
60         98   Tobacco  2016 US Dollar    517.466504    343.789930
61         98   Tobacco  2016 US Dollar   5858.348322   4965.560873
62         98   Tobacco  2016 US Dollar  33276.545480  29740.534840
63         98   Tobacco  2016 US Dollar  29654.174070  26291.391010
64         98   Tobacco  2016 US Dollar  69306.534370  62651.505670
...       ...       ...             ...           ...           ...
1176       98   Tobacco  2016 US Dollar   8222.271063   6747.414164
1177       98   Tobacco  2016 US Dollar    692.063133    407.813810
1178       98   Tobacco  2016 US Dollar   5600.259499   4531.227772
1179       98   Tobacco  2016 US Dollar   8758.646080   7274.289789
1180       98   Tobacco  2016 US Dollar  15050.968710  12542.772790

            upper
60      712.649285
61     6851.740572
62    36737.606660
63    33371.325550
64    76505.313690
...            ...
1176   9796.790450
1177    951.909694
1178   6718.759946
1179  10505.380740
1180  17889.599790

[126 rows x 15 columns]
```

In [21]:
```python
# 17. Wybór wierszy, gdzie kolumna kategoryczna NIE zawiera określonego słowa

# Kolumna do filtrowania i słowo kluczowe
kolumna_filtrowana = "risk_name"
slowo_kluczowe = "Tobacco"  # Możesz zmienić na inne słowo
```

```
# Sprawdzenie, czy kolumna istnieje
if kolumna_filtrowana in ramka_danych_csv.columns:
    print(f"\nWiersze, gdzie kolumna '{kolumna_filtrowana}' NIE zawiera słowa '{
    print(ramka_danych_csv[~ramka_danych_csv[kolumna_filtrowana].str.contains(sl
else:
    print(f"\nBłąd: Kolumna '{kolumna_filtrowana}' nie istnieje w ramce danych."
```

```
Wiersze, gdzie kolumna 'risk_name' NIE zawiera słowa 'Tobacco':
      location_id            location_name  year  sex_id   sex  age_group_id  \
0             102  United States of America  2016       1  Male           158
1             102  United States of America  2016       1  Male           170
2             102  United States of America  2016       1  Male           171
3             102  United States of America  2016       1  Male           154
4             102  United States of America  2016       1  Male            22
...           ...                       ...   ...     ...   ...           ...
1236          102  United States of America  2016       3  Both           158
1237          102  United States of America  2016       3  Both           170
1238          102  United States of America  2016       3  Both           171
1239          102  United States of America  2016       3  Both           154
1240          102  United States of America  2016       3  Both            22

     age_group_name acause                  cause_name  risk_id  \
0         <20 years   _all                 All causes       82
1          20 to 44   _all                 All causes       82
2          45 to 64   _all                 All causes       82
3           65 plus   _all                 All causes       82
4          All Ages   _all                 All causes       82
...             ...    ...                         ...      ...
1236      <20 years     rf  Expenditure on risk factors      108
1237       20 to 44     rf  Expenditure on risk factors      108
1238       45 to 64     rf  Expenditure on risk factors      108
1239        65 plus     rf  Expenditure on risk factors      108
1240       All Ages     rf  Expenditure on risk factors      108

                                    risk_name          metric         mean  \
0     Unsafe water, sanitation, and handwashing  2016 US Dollar    52.810750
1     Unsafe water, sanitation, and handwashing  2016 US Dollar    48.000244
2     Unsafe water, sanitation, and handwashing  2016 US Dollar    69.765933
3     Unsafe water, sanitation, and handwashing  2016 US Dollar    88.960404
4     Unsafe water, sanitation, and handwashing  2016 US Dollar   259.537331
...                                         ...            ...          ...
1236                      High body-mass index  2016 US Dollar   186.043387
1237                      High body-mass index  2016 US Dollar  3697.662630
1238                      High body-mass index  2016 US Dollar  4403.916422
1239                      High body-mass index  2016 US Dollar  1457.018966
1240                      High body-mass index  2016 US Dollar  9744.641404

            lower         upper
0       34.776353     76.466271
1       31.644490     70.893323
2       45.764417    101.797946
3       59.168652    128.091201
4      171.226033    375.015989
...           ...           ...
1236   142.143526    232.865620
1237  2626.047083   4824.208117
1238  3083.734761   5662.947080
1239  1104.520225   2292.252672
1240  7222.418431  12418.772000

[1115 rows x 15 columns]
```

In [27]:
```python
# 18. Tworzenie nowej kolumny na podstawie istniejących

# Sprawdzenie dostępnych kolumn w pliku
print("\nDostępne kolumny w ramce danych:")
print(ramka_danych_csv.columns)
```

```
# Wybór odpowiednich kolumn do obliczeń
kolumna_istniejaca1 = "spending_mean"  # Przykładowa kolumna z wydatkami
kolumna_istniejaca2 = "population"  # Przykładowa kolumna z populacją
nowa_kolumna = "spending_per_capita"  # Nazwa nowej kolumny

# Sprawdzenie, czy wymagane kolumny istnieją w danych
if kolumna_istniejaca1 in ramka_danych_csv.columns and kolumna_istniejaca2 in ra
    # Tworzenie nowej kolumny jako iloraz dwóch istniejących wartości
    ramka_danych_csv[nowa_kolumna] = ramka_danych_csv[kolumna_istniejaca1] / ram

    print(f"\nNowa kolumna '{nowa_kolumna}' została utworzona na podstawie '{kol
    print(ramka_danych_csv[[kolumna_istniejaca1, kolumna_istniejaca2, nowa_kolum
```

```
Dostępne kolumny w ramce danych:
Index(['location_id', 'location_name', 'year', 'sex_id', 'sex', 'age_group_id',
       'age_group_name', 'acause', 'cause_name', 'risk_id', 'risk_name',
       'metric', 'mean', 'lower', 'upper'],
      dtype='object')
```

In [29]:
```
# 21. Usunięcie kolumny z ramki danych

kolumna_do_usuniecia = "spending_per_capita"  # Podaj nazwę kolumny do usunięcia

# Sprawdzenie, czy kolumna istnieje w danych
if kolumna_do_usuniecia in ramka_danych_csv.columns:
    ramka_danych_csv = ramka_danych_csv.drop(columns=[kolumna_do_usuniecia])
    print(f"\nKolumna '{kolumna_do_usuniecia}' została usunięta.")

# Wyświetlenie aktualnych kolumn po usunięciu
print("\nAktualne kolumny w ramce danych:")
print(ramka_danych_csv.columns)
```

```
Aktualne kolumny w ramce danych:
Index(['location_id', 'location_name', 'year', 'sex_id', 'sex', 'age_group_id',
       'age_group_name', 'acause', 'cause_name', 'risk_id', 'risk_name',
       'metric', 'mean', 'lower', 'upper'],
      dtype='object')
```

In [30]:
```
# 22. Zmiana nazwy kolumny w ramce danych

stara_nazwa = "spending_mean"  # Podaj aktualną nazwę kolumny
nowa_nazwa = "average_spending"  # Podaj nową nazwę kolumny

# Sprawdzenie, czy kolumna istnieje
if stara_nazwa in ramka_danych_csv.columns:
    ramka_danych_csv = ramka_danych_csv.rename(columns={stara_nazwa: nowa_nazwa}
    print(f"\nZmieniono nazwę kolumny '{stara_nazwa}' na '{nowa_nazwa}'.")
else:
    print(f"\nBłąd: Kolumna '{stara_nazwa}' nie istnieje w ramce danych.")

# Wyświetlenie aktualnych nazw kolumn
print("\nAktualne kolumny w ramce danych:")
print(ramka_danych_csv.columns)
```

```
Błąd: Kolumna 'spending_mean' nie istnieje w ramce danych.

Aktualne kolumny w ramce danych:
Index(['location_id', 'location_name', 'year', 'sex_id', 'sex', 'age_group_id',
       'age_group_name', 'acause', 'cause_name', 'risk_id', 'risk_name',
       'metric', 'mean', 'lower', 'upper'],
      dtype='object')
```

In [32]:
```
# 20. Zmień nazwę kolumny
ramka_danych_csv = ramka_danych_csv.rename(columns={'location_name': 'location_c
```

In [34]:
```
print(ramka_danych_csv.columns)
```

```
Index(['location_id', 'location_country', 'year', 'sex_id', 'sex',
       'age_group_id', 'age_group_name', 'acause', 'cause_name', 'risk_id',
       'risk_name', 'metric', 'mean', 'lower', 'upper'],
      dtype='object')
```

In [35]:
```
# 21. Zachowaj ramkę danych jako plik csv na komputerze
ramka_danych_csv.to_csv('updated_data.csv', index=False)
```

In [36]:
```
# 22. Wyświetlić liczbę wierszy
print(len(ramka_danych_csv))
```

```
1241
```

In [37]:
```
# 23. Wyświetlić wartości unikatowe w kolumnie
print(ramka_danych_csv['location_country'].unique())
```

```
['United States of America']
```

In [38]:
```
# 24. Wyświetlić liczby rekordów odpowiadających do wartości
print(ramka_danych_csv['location_country'].value_counts())
```

```
location_country
United States of America    1241
Name: count, dtype: int64
```

In [40]:
```
# 25. Sortowanie wierszy ramki danych według wartości określonej kolumny (malejąc
ramka_danych_csv = ramka_danych_csv.sort_values(by='location_country', ascending
```

In [41]:
```
# 26. Wyświetlić wierszy dla 10 największych (najmniejszych) wartości określonej
print(ramka_danych_csv.nlargest(10, 'upper'))
print(ramka_danych_csv.nsmallest(10, 'upper'))
```

```
     location_id          location_country  year  sex_id     sex  \
147          102  United States of America  2016       3    Both
238          102  United States of America  2016       3    Both
251          102  United States of America  2016       3    Both
142          102  United States of America  2016       2  Female
171          102  United States of America  2016       3    Both
74           102  United States of America  2016       3    Both
146          102  United States of America  2016       3    Both
137          102  United States of America  2016       1    Male
145          102  United States of America  2016       3    Both
460          102  United States of America  2016       3    Both

     age_group_id age_group_name acause  \
147            22       All Ages   _all
238            22       All Ages   _all
251            22       All Ages   _all
142            22       All Ages   _all
171            22       All Ages   _all
74             22       All Ages   _all
146           154        65 plus   _all
137            22       All Ages   _all
145           171       45 to 64   _all
460            22       All Ages  _dube

                                          cause_name  risk_id  \
147                                       All causes      108
238                                       All causes      341
251                                       All causes      367
142                                       All causes      108
171                                       All causes      110
74                                        All causes       98
146                                       All causes      108
137                                       All causes      108
145                                       All causes      108
460  Diabetes and urogenital, blood, and endocrine ...      105

                      risk_name          metric         mean         lower  \
147         High body-mass index  2016 US Dollar  238503.4055  178217.18940
238  High systolic blood pressure  2016 US Dollar  179903.7277  164459.06720
251   High fasting plasma glucose  2016 US Dollar  171932.5283  154821.07370
142         High body-mass index  2016 US Dollar  133082.2466  100602.17950
171                Dietary risks  2016 US Dollar  143551.7276  130343.09990
74                       Tobacco  2016 US Dollar  129959.6416  116812.01360
146         High body-mass index  2016 US Dollar  101327.8710   69506.57512
137         High body-mass index  2016 US Dollar  105421.1590   76396.68290
145         High body-mass index  2016 US Dollar  109030.3703   85125.38710
460   High fasting plasma glucose  2016 US Dollar  120366.3232  113086.49690

          upper
147  291573.7532
238  195962.0712
251  191940.1801
142  162581.4562
171  156080.6003
74   143525.1170
146  132702.6808
137  131279.1270
145  128130.7642
460  126741.3779
     location_id          location_country  year  sex_id     sex  \
```

```
1033          102  United States of America  2016       2  Female
1149          102  United States of America  2016       2  Female
874           102  United States of America  2016       2  Female
1028          102  United States of America  2016       1    Male
1038          102  United States of America  2016       3    Both
730           102  United States of America  2016       1    Male
735           102  United States of America  2016       2  Female
688           102  United States of America  2016       1    Male
693           102  United States of America  2016       2  Female
849           102  United States of America  2016       2  Female

      age_group_id age_group_name     acause                cause_name  \
1033           158      <20 years        cvd    Cardiovascular diseases
1149           170       20 to 44        msk  Musculoskeletal disorders
874            158      <20 years  cirrhosis                  Cirrhosis
1028           158      <20 years        cvd    Cardiovascular diseases
1038           158      <20 years        cvd    Cardiovascular diseases
730            158      <20 years       _neo                 Neoplasms
735            158      <20 years       _neo                 Neoplasms
688            158      <20 years       _neo                 Neoplasms
693            158      <20 years       _neo                 Neoplasms
849            170       20 to 44     _neuro     Neurological disorders

      risk_id                   risk_name          metric      mean  \
1033      126           Occupational risks  2016 US Dollar  0.058442
1149      341     Impaired kidney function  2016 US Dollar  0.304079
874       102                  Alcohol use  2016 US Dollar  0.376233
1028      126           Occupational risks  2016 US Dollar  0.375501
1038      126           Occupational risks  2016 US Dollar  0.433943
730       103                     Drug use  2016 US Dollar  0.717406
735       103                     Drug use  2016 US Dollar  0.950784
688        89    Other environmental risks  2016 US Dollar  0.642990
693        89    Other environmental risks  2016 US Dollar  0.634566
849       105  High fasting plasma glucose  2016 US Dollar  0.662740

         lower     upper
1033  0.018899  0.105215
1149  0.217169  0.433294
874   0.217804  0.589010
1028  0.138020  0.642662
1038  0.187088  0.706757
730   0.501235  0.984388
735   0.689007  1.298707
688   0.107717  1.450370
693   0.105842  1.507581
849   0.100641  1.695272
```

In [42]:
```
# 27. Wyświetlić wierszy dla 10 największych wartości określonej kolumny pod war
filtered_data = ramka_danych_csv[ramka_danych_csv['location_country'] == 'Global
print(filtered_data.nlargest(10, 'lower'))
```

```
Empty DataFrame
Columns: [location_id, location_country, year, sex_id, sex, age_group_id, age_gro
up_name, acause, cause_name, risk_id, risk_name, metric, mean, lower, upper]
Index: []
```

In [44]:
```
# 28. Grupowanie wierszy według wartości kolumny skategoryzowanej, potem uśredni
grouped_mean = ramka_danych_csv.groupby(['location_country', 'year']).mean(numer
print(grouped_mean)
```

```
                                location_id    sex_id  age_group_id  \
location_country         year
United States of America 2016        102.0  2.020145    132.887188

                                   risk_id         mean        lower  \
location_country         year
United States of America 2016  129.024174  7523.642696  5972.186569

                                     upper
location_country         year
United States of America 2016  9227.09898
```

In [45]:
```
# 29. Grupowanie wierszy według wartości kolumny skategoryzowanej, potem uśredni
grouped_stats = ramka_danych_csv.groupby('upper').agg({
    'upper': ['mean', 'count'],
    'upper': 'median',
    'year': 'max'
})
print(grouped_stats)
```

```
                       upper  year
upper
0.105215            0.105215  2016
0.433294            0.433294  2016
0.589010            0.589010  2016
0.642662            0.642662  2016
0.706757            0.706757  2016
...                      ...   ...
156080.600300  156080.600300  2016
162581.456200  162581.456200  2016
191940.180100  191940.180100  2016
195962.071200  195962.071200  2016
291573.753200  291573.753200  2016

[1145 rows x 2 columns]
```

In [46]:
```
# 30. Wyświetlić nazwy kolumn indeksu złożonego
print(grouped_mean.index.names)
```

```
['location_country', 'year']
```

In [47]:
```
# 31. Posortować kolumnę, indeksu złożonego
sorted_index = grouped_mean.sort_index()
print(sorted_index)
```

```
                                location_id    sex_id  age_group_id  \
location_country         year
United States of America 2016        102.0  2.020145    132.887188

                                   risk_id         mean        lower  \
location_country         year
United States of America 2016  129.024174  7523.642696  5972.186569

                                     upper
location_country         year
United States of America 2016  9227.09898
```

In [48]:
```
# 32. Stworzyć tabele przestawną (pivot table) na podstawie ramki danych
pivot_table = pd.pivot_table(ramka_danych_csv, values='upper', index=['location_
print(pivot_table)
```

```
year                              2016
location_country
United States of America  9227.09898
```

In [49]:
```
# 33. Wyświetlić indeksy i kolumny tabeli przestawnej
print(pivot_table.index)
print(pivot_table.columns)
```

```
Index(['United States of America'], dtype='object', name='location_country')
Index([2016], dtype='int64', name='year')
```

In [50]:
```
# 34. Utwórz indeks złożony tabeli przestawnej i wyświetl go
pivot_table = pivot_table.reset_index()
pivot_table.set_index(['location_country'] + list(pivot_table.columns[1:]), inpl
print(pivot_table.index)
```

```
MultiIndex([('United States of America', 9227.098980246341)],
           names=['location_country', 2016])
```

In [2]:
```
35# Importujemy potrzebne biblioteki
import pandas as pd
import matplotlib.pyplot as plt

36-37# Załaduj plik CSV
file_path = 'IHME_USA_RISK_SPENDING_2016_Y2020M09D29.csv'
df = pd.read_csv(file_path)

# Ustawienie, by wykresy były widoczne bezpośrednio w notebooku
%matplotlib inline

# Przekształcamy dane do formatu "długiego" z użyciem melt
df_melted = df[['year', 'risk_name', 'age_group_name', 'mean']]

# Filtrujemy dane, np. dla konkretnego ryzyka
df_risk = df_melted[df_melted['risk_name'] == 'Unsafe water, sanitation, and han

# Grupujemy dane według roku i grupy wiekowej, obliczając średnią wartość
df_grouped = df_risk.groupby(['year', 'age_group_name'])['mean'].mean().reset_in

# Tworzymy wykres
plt.figure(figsize=(10, 6))
for age_group in df_grouped['age_group_name'].unique():
    data = df_grouped[df_grouped['age_group_name'] == age_group]
    plt.plot(data['year'], data['mean'], label=f'Age group: {age_group}')

# Dodajemy etykiety, legendę i tytuł
plt.xlabel('Year')
plt.ylabel('Mean Value (2016 US Dollar)')
plt.title('Mean Values for Unsafe Water, Sanitation, and Handwashing by Age Grou
plt.legend(title='Age Groups')
plt.grid(True)

# Pokaż wykres
plt.show()
```

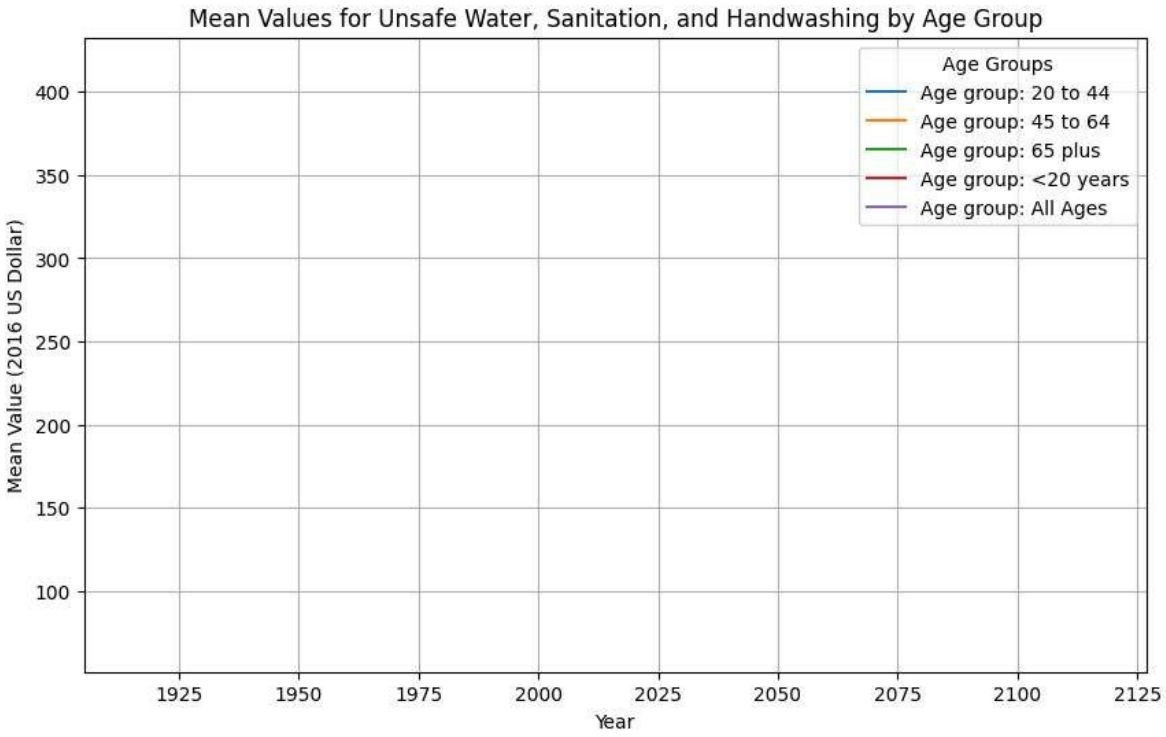

In [3]:
```python
# 38 Importujemy potrzebne biblioteki
import pandas as pd
import matplotlib.pyplot as plt

# Załaduj plik CSV
file_path = 'IHME_USA_RISK_SPENDING_2016_Y2020M09D29.csv'
df = pd.read_csv(file_path)

# Ustawienie, by wykresy były widoczne bezpośrednio w notebooku
%matplotlib inline

# Wybieramy kolumnę, np. 'mean', do narysowania histogramu
column_to_plot = 'mean'

# Rysowanie histogramu
plt.figure(figsize=(10, 6))
plt.hist(df[column_to_plot], bins=30, edgecolor='black')

# Dodajemy etykiety i tytuł
plt.xlabel(f'{column_to_plot} Value')
plt.ylabel('Frequency')
plt.title(f'Histogram of {column_to_plot}')

# Pokaż wykres
plt.show()
```

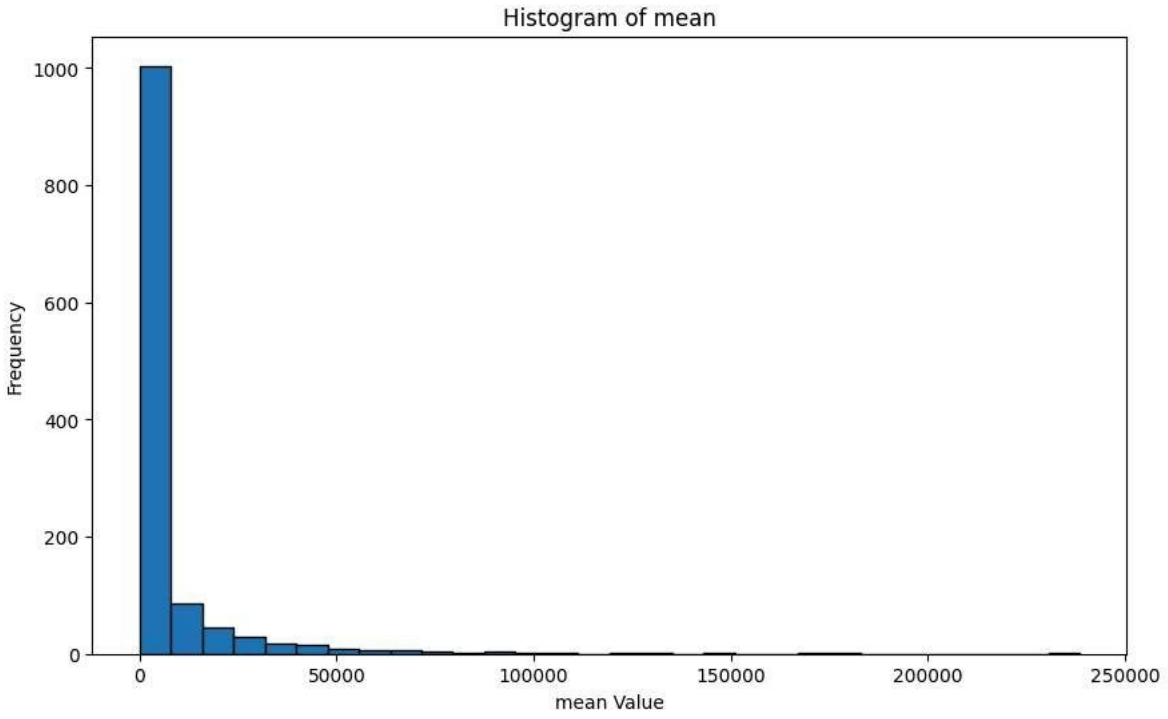

In [4]:
```python
# 39. Przedstawić sposoby łączenia ramek danych za pomocą metod merge i concat
# Metoda merge:
df1 = pd.DataFrame({'key': ['A', 'B', 'C'], 'value1': [1, 2, 3]})
df2 = pd.DataFrame({'key': ['A', 'B', 'D'], 'value2': [4, 5, 6]})
merged_df = pd.merge(df1, df2, on='key', how='inner')
print(merged_df)
# Metoda konkatenacji:
df3 = pd.DataFrame({'key': ['A', 'B'], 'value1': [7, 8]})
df4 = pd.DataFrame({'key': ['C', 'D'], 'value1': [9, 10]})
concatenated_df = pd.concat([df3, df4], ignore_index=True)
print(concatenated_df)
```

```
  key  value1  value2
0   A       1       4
1   B       2       5
  key  value1
0   A       7
1   B       8
2   C       9
3   D      10
```

In [6]:
```python
# 40Importujemy potrzebne biblioteki
import pandas as pd

# Załaduj plik CSV
file_path = 'IHME_USA_RISK_SPENDING_2016_Y2020M09D29.csv'
df = pd.read_csv(file_path)

# Ustawienie, by wykresy były widoczne bezpośrednio w notebooku
%matplotlib inline

# 1. Dodanie kolumny różnicy między 'upper' a 'lower'
df['difference_upper_lower'] = df['upper'] - df['lower']

# 2. Dodanie kolumny średniej wartości z 'mean', 'upper' i 'lower'
df['average_value'] = (df['mean'] + df['upper'] + df['lower']) / 3

# 3. Dodanie kolumny, która będzie wynikiem mnożenia 'mean' przez 1.1 (np. 10% w
```

```
df['mean_increased_10_percent'] = df['mean'] * 1.1

# Wyświetlamy pierwsze 5 wierszy, aby sprawdzić nowe kolumny
df[['year', 'risk_name', 'mean', 'upper', 'lower', 'difference_upper_lower', 'av
```

Out[6]:

	year	risk_name	mean	upper	lower	difference_upper_lower	aver
0	2016	Unsafe water, sanitation, and handwashing	52.810750	76.466271	34.776353	41.689918	
1	2016	Unsafe water, sanitation, and handwashing	48.000244	70.893323	31.644490	39.248833	
2	2016	Unsafe water, sanitation, and handwashing	69.765933	101.797946	45.764417	56.033530	
3	2016	Unsafe water, sanitation, and handwashing	88.960404	128.091201	59.168652	68.922549	
4	2016	Unsafe water, sanitation, and handwashing	259.537331	375.015989	171.226033	203.789956	2

In [8]:

```
# 41 Importujemy bibliotekę
import pandas as pd

# Załaduj plik CSV
file_path = 'IHME_USA_RISK_SPENDING_2016_Y2020M09D29.csv'
df = pd.read_csv(file_path)

# 1. Tworzenie nowej kolumny "risk_level" na podstawie wartości 'mean'
mean_threshold = df['mean'].mean()  # Obliczamy średnią wartość mean
df['risk_level'] = df['mean'].apply(lambda x: 'High' if x > mean_threshold else

# 2. Zamiana nazw płci na skróconą formę ("Male" → "M", "Female" → "F")
df['sex_short'] = df['sex'].apply(lambda x: 'M' if x == 'Male' else 'F')

# 3. Kategoryzacja wieku (jeśli "plus" w nazwie grupy wiekowej, oznaczamy jako "
df['age_category'] = df['age_group_name'].apply(lambda x: 'Senior' if 'plus' in

# Wyświetlamy kilka pierwszych wierszy z nowymi kolumnami
df[['year', 'risk_name', 'mean', 'risk_level', 'sex', 'sex_short', 'age_group_na
```

Out[8]:

	year	risk_name	mean	risk_level	sex	sex_short	age_group_name	age_cat
0	2016	Unsafe water, sanitation, and handwashing	52.810750	Low	Male	M	<20 years	
1	2016	Unsafe water, sanitation, and handwashing	48.000244	Low	Male	M	20 to 44	
2	2016	Unsafe water, sanitation, and handwashing	69.765933	Low	Male	M	45 to 64	
3	2016	Unsafe water, sanitation, and handwashing	88.960404	Low	Male	M	65 plus	
4	2016	Unsafe water, sanitation, and handwashing	259.537331	Low	Male	M	All Ages	

In [12]:
```
# 42. Przedstawić możliwości pracy z dużymi plikami przy użyciu argumentu chunks
chunksize = 10000
for chunk in pd.read_csv('IHME_USA_RISK_SPENDING_2016_Y2020M09D29.csv', chunksiz
    print(chunk.head(4))
```

```
   location_id            location_name  year  sex_id   sex  age_group_id  \
0          102  United States of America  2016       1  Male           158
1          102  United States of America  2016       1  Male           170
2          102  United States of America  2016       1  Male           171
3          102  United States of America  2016       1  Male           154

  age_group_name acause  cause_name  risk_id  \
0      <20 years   _all  All causes       82
1       20 to 44   _all  All causes       82
2       45 to 64   _all  All causes       82
3        65 plus   _all  All causes       82

                                 risk_name          metric       mean  \
0  Unsafe water, sanitation, and handwashing  2016 US Dollar  52.810750
1  Unsafe water, sanitation, and handwashing  2016 US Dollar  48.000244
2  Unsafe water, sanitation, and handwashing  2016 US Dollar  69.765933
3  Unsafe water, sanitation, and handwashing  2016 US Dollar  88.960404

       lower       upper
0  34.776353   76.466271
1  31.644490   70.893323
2  45.764417  101.797946
3  59.168652  128.091201
```

In [ ]:

3. Wnioski z wykonanego kodu:
Ćwiczenie koncentruje się na podstawowych operacjach związanych z analizą danych przy użyciu biblioteki **pandas**. Wykorzystuje różne sposoby tworzenia ramek danych, co pokazuje elastyczność tej biblioteki. Dane są konstruowane zarówno ze słownika, jak i z listy list, a także wczytywane z pliku CSV, co pozwala na szybkie i wygodne przekształcanie informacji do struktury umożliwiającej dalszą analizę.
Wczytywanie danych z pliku CSV to kluczowy element pracy z rzeczywistymi zbiorami danych, ponieważ umożliwia automatyczne załadowanie dużych ilości informacji do struktury DataFrame. Dzięki funkcji `head()` można łatwo uzyskać podgląd pierwszych kilku wierszy, co pomaga w weryfikacji poprawności zaimportowanych danych. Dodatkowo, kod pokazuje, jak przekształcać ramki danych, np. poprzez transponowanie, co jest przydatne w przypadku zmiany perspektywy analizy.

Zastosowanie pandas pozwala na efektywne organizowanie, filtrowanie i modyfikowanie zbiorów danych. Choć kod skupia się na podstawowych operacjach, można go rozszerzyć o bardziej zaawansowane analizy, takie jak grupowanie, filtrowanie czy wizualizacja danych przy użyciu bibliotek takich jak **Matplotlib** czy **Seaborn**. Podsumowując, notebook stanowi dobre wprowadzenie do pracy z pandas i może być dalej rozwijany w kierunku bardziej złożonych analiz danych.