In [4]:
```python
# 0. Krzysztof Świerczek Przygotowanie danych

import pandas as pd
import seaborn as sns
import plotly.express as px
import plotly.graph_objects as go
import matplotlib.pyplot as plt
from sklearn.ensemble import IsolationForest
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

df = pd.read_csv('final_solution.csv')
#print(df.info())
#print(df.describe())
numerical_features = ['age', 'income', 'outcome']
numerical_df = df[numerical_features]

if numerical_df.isnull().sum().any():
    numerical_df.fillna(numerical_df.mean(), inplace=True)
```

In [5]:
```python
# 1. Krzysztof Świerczek Zidentyfikować wartości odstające za pomocą algorytmu I

scaler = StandardScaler()
numerical_df_scaled = scaler.fit_transform(numerical_df)

# Model Isolation Forest
iso_forest = IsolationForest(contamination=0.05, random_state=42)
df['Wartości odstające'] = iso_forest.fit_predict(numerical_df_scaled)

# Oznaczenie wartości odstających (-1 oznacza odstające, 1 oznacza normalne)
df['Wartości odstające'] = df['Wartości odstające'].apply(lambda x: 'Odstające'

# Wizualizacja wyników
plt.figure(figsize=(10, 6))
sns.countplot(data=df, x='Wartości odstające')
plt.title("Rozkład wartości odstających dla danych")
plt.show()

# Analiza zmiennych z uwzględnieniem odstających wartości
plt.figure(figsize=(12, 8))
sns.boxplot(data=df, x='Wartości odstające', y='income')
plt.title("Dochód w podziale na wartości odstające")
plt.show()
```

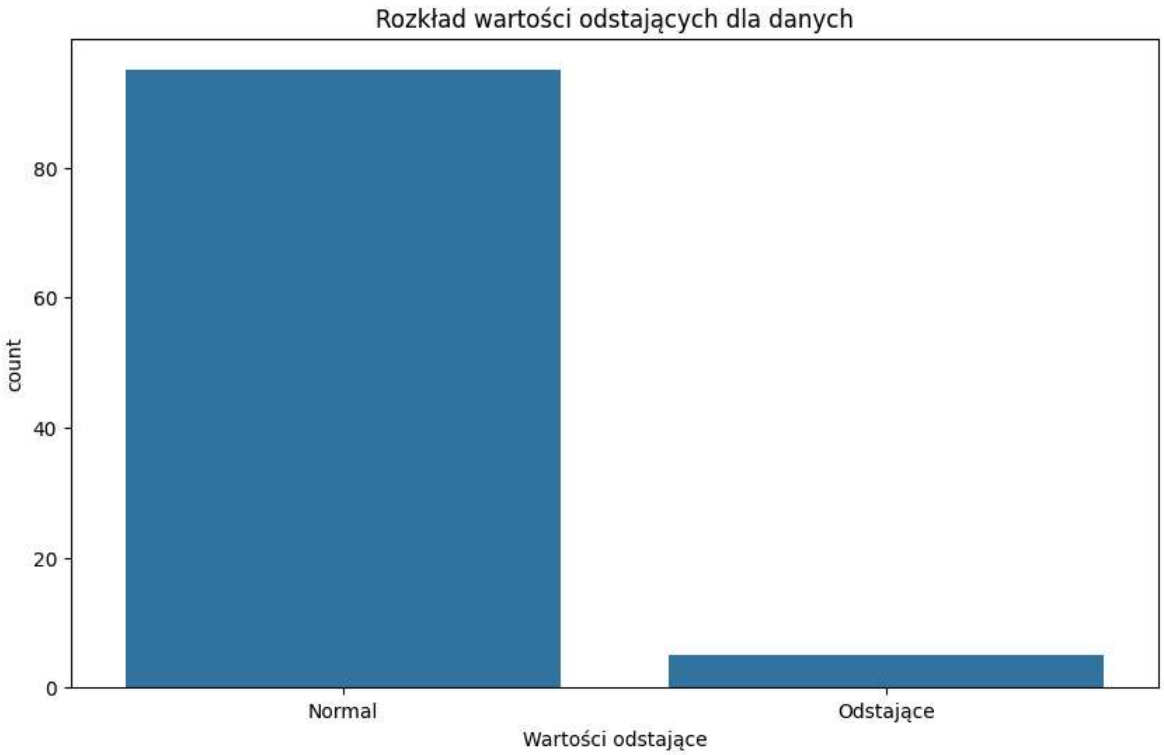

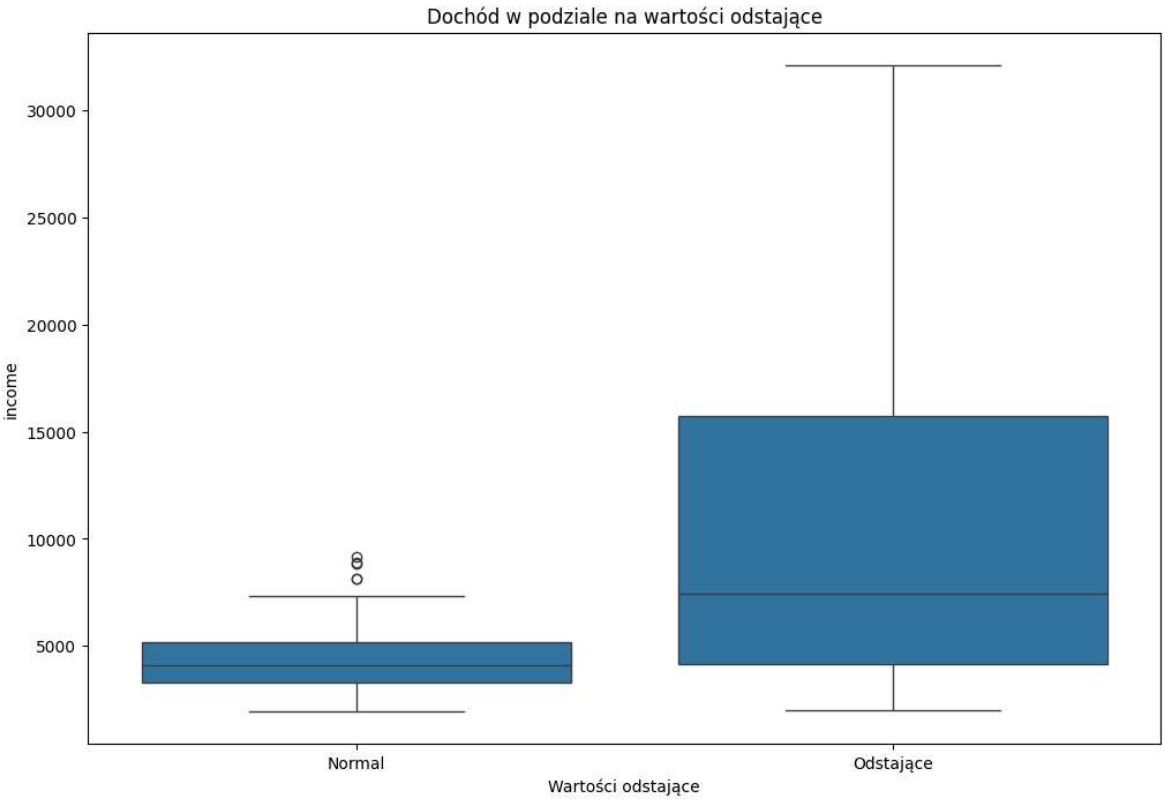

In [6]:
```
# 2. Krzysztof Świerczek Redukować wymiarowość danych z użyciem PCA,
# Redukcja do 2 wymiarów
pca = PCA(n_components=2)
pca_result = pca.fit_transform(numerical_df_scaled)
df['PC1'] = pca_result[:, 0]
df['PC2'] = pca_result[:, 1]

# Wynik w formie DataFrame
pca_df = pd.DataFrame(pca_result, columns=['PC1', 'PC2'])

explained_variance = pca.explained_variance_ratio_
print(f"Wariancja wyjaśniana przez każdą składową: {explained_variance}")
```

```
print(f"Łączna wariancja: {sum(explained_variance):.2f}")

plt.figure(figsize=(8, 6))
plt.scatter(pca_df['PC1'], pca_df['PC2'], alpha=0.7)
plt.xlabel('PC1')
plt.ylabel('PC2')
plt.title('Wizualizacja danych po PCA')
plt.show()
```

```
Wariancja wyjaśniana przez każdą składową: [0.41987303 0.33992199]
Łączna wariancja: 0.76
```

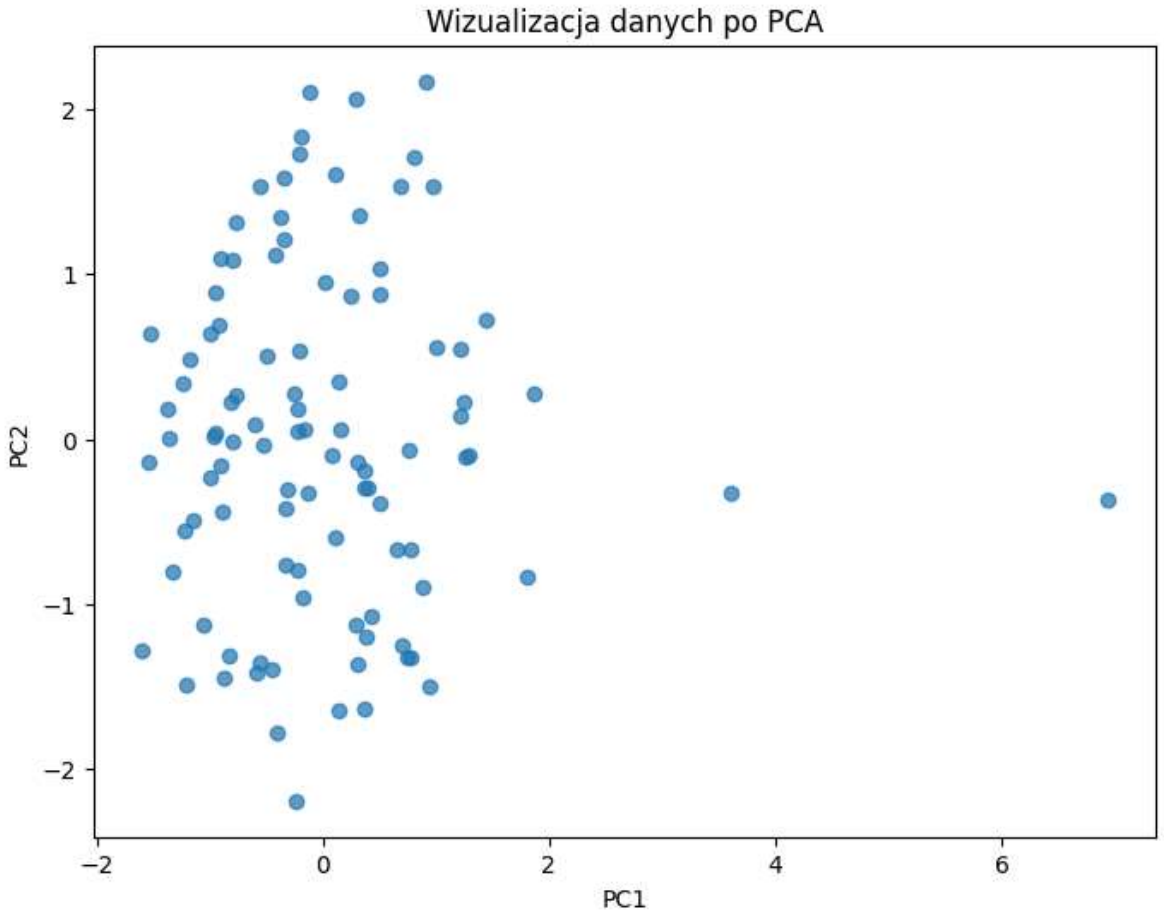

In [7]:
```
# 3. Krzysztof Świerczek Tworzyć zaawansowane interaktywne wizualizacje danych,
df['Różnica między dochodami a wydatkami'] = df['income'] - df['outcome']
fig_pca = px.scatter(df, x='Różnica między dochodami a wydatkami', y='savings',
fig_pca.show()
```

In [8]:
```
fig_box = px.box(df, x='Wartości odstające', y='income', color='Wartości odstają
                 title='Rozkład dochodów w zależności od wartości odstających')
fig_box.show()
```

In [9]:
```
fig_hist = px.histogram(df, x='Wartości odstające', color='Wartości odstające',
                        title='Rozkład wartości odstających w danych', marginal=
fig_hist.show()
```

In [10]:
```
fig_children_income = px.scatter(df, x='children', y='income', color='income', h
                                 title='Zależność między liczbą dzieci a dochode
fig_children_income.show()
```

In [13]:
```
# 4. Zwizualizować dane wielowymiarowe za pomocą zaawansowanych algorytmów (t-SN

from sklearn.manifold import TSNE
from umap import UMAP


columns_of_interest = ['age', 'income', 'outcome', 'savings', 'credit_score', 's
X = df[columns_of_interest]

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# Użycie UMAP do redukcji wymiarowości
umap_model = UMAP(n_components=2, random_state=42)
umap_results = umap_model.fit_transform(X_scaled)

tsne_model = TSNE(n_components=2, random_state=42, perplexity=30, n_iter=300)
tsne_results = tsne_model.fit_transform(X_scaled)

umap_df = pd.DataFrame(umap_results, columns=['UMAP1', 'UMAP2'])
tsne_df = pd.DataFrame(tsne_results, columns=['t-SNE1', 't-SNE2'])
df_umap = pd.concat([df, umap_df], axis=1)
df_tsne = pd.concat([df, tsne_df], axis=1)

# UMAP
plt.figure(figsize=(10, 8))
sns.scatterplot(data=df_umap, x='UMAP1', y='UMAP2', hue='city', palette='viridis
plt.title('UMAP Visualization')
```

```
plt.show()

# t-SNE
plt.figure(figsize=(10, 8))
sns.scatterplot(data=df_tsne, x='t-SNE1', y='t-SNE2', hue='city', palette='virid
plt.title('t-SNE Visualization')
plt.show()
```

```
---------------------------------------------------------------------------
ImportError                               Traceback (most recent call last)
Cell In[13], line 4
      1 # 4. Zwizualizować dane wielowymiarowe za pomocą zaawansowanych algorytmó
w (t-SNE, UMAP)
      3 from sklearn.manifold import TSNE
----> 4 from umap import UMAP
      7 columns_of_interest = ['age', 'income', 'outcome', 'savings', 'credit_sco
re', 'spending_score']
      8 X = df[columns_of_interest]

ImportError: cannot import name 'UMAP' from 'umap' (C:\Users\krzys\AppData\Local
\Programs\Python\Python310\lib\site-packages\umap\__init__.py)
```

In [14]:
```
# 6. Analizować zależności między zmiennymi za pomocą macierzy korelacji.
import plotly.figure_factory as ff

#Numeric dataframe:
numerical_features = ['income', 'outcome', 'savings']
numeric_df = df[numerical_features]
correlation_matrix = numeric_df.corr()
fig = ff.create_annotated_heatmap(
    z=correlation_matrix.values,
    x=correlation_matrix.columns.tolist(),
    y=correlation_matrix.columns.tolist(),
    colorscale='Viridis',
    showscale=True,
)

fig.update_layout(title="Macierz korelacji zmiennych")
fig.show()
```

In [16]:
```python
# 7. Przeprowadzać testy statystyczne dla analizy różnic w grupach.

from scipy import stats
from statsmodels.formula.api import ols
from statsmodels.stats.anova import anova_lm
from scipy.stats import chi2_contingency

# Test T-studenta
group1 = df[df['employment_status'] == 'employed']['income']
group2 = df[df['employment_status'] == 'retired']['income']

t_stat, p_value = stats.ttest_ind(group1, group2)

print(f"T-statystyka: {t_stat}")
print(f"P-wartość: {p_value}")
if p_value < 0.05:
    print("Istnieje istotna różnica w średnich income między grupą zatrudnionych
else:
    print("Brak istotnej różnicy w średnich income między grupą zatrudnionych a


# Test ANOVA
model = ols('outcome ~ employment_status', data=df).fit()
anova_table = anova_lm(model)

print(anova_table)

if anova_table['PR(>F)'][0] < 0.05:
```

```
    print("Istnieje istotna różnica w średnich outcome między przynajmniej dwoma
else:
    print("Brak istotnej różnicy w średnich outcome między przynajmniej dwoma gr

# Test Chi-kwadrat
contingency_table = pd.crosstab(df['employment_status'], df['city'])

chi2_stat, p_val, dof, expected = chi2_contingency(contingency_table)

print(f"Chi-kwadrat statystyka: {chi2_stat}")
print(f"P-wartość: {p_val}")

if p_val < 0.05:
    print("Istnieje istotna zależność między employment_status a city. (np. w Wa
else:
    print("Brak istotnej zależności między employment_status a city.")
```

```
T-statystyka: 1.9184754519058442
P-wartość: 0.06258664760296179
Brak istotnej różnicy w średnich income między grupą zatrudnionych a emerytami.
                    df        sum_sq       mean_sq         F    PR(>F)
employment_status   3.0  4.239691e+06  1.413230e+06  2.035066  0.114095
Residual           96.0  6.666619e+07  6.944395e+05       NaN       NaN
Brak istotnej różnicy w średnich outcome między przynajmniej dwoma grupami employ
ment_status.
Chi-kwadrat statystyka: 32.33963867527266
P-wartość: 0.6434063139648425
Brak istotnej zależności między employment_status a city.
C:\Users\krzys\AppData\Local\Temp\ipykernel_6404\1644763415.py:28: FutureWarning:

Series.__getitem__ treating keys as positions is deprecated. In a future version,
integer keys will always be treated as labels (consistent with DataFrame behavio
r). To access a value by position, use `ser.iloc[pos]`
```

In [ ]: