In [1]:
```
# 0. Krzuysztof Świerczek Przygotowanie danych

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy.stats import probplot
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression, Ridge
from sklearn.neural_network import MLPRegressor
from sklearn.metrics import mean_squared_error


df = pd.read_csv('final_solution.csv')
numeryczne_kolumny = ['age', 'income', 'outcome']
numeryczny_df = df[numeryczne_kolumny]

if numeryczny_df.isnull().sum().any():
    numeryczny_df.fillna(numeryczny_df.mean(), inplace=True)
```

In [6]:
```
# 1.  Krzysztofg świerczek W Pythonie, R oraz KNIME porównaj wyniki regresji lin

# Features and target variable
X = df[['age', 'income', 'savings', 'children', 'credit_score', 'spending_score'
y = df['outcome']

# Split data into training and testing sets
X_treningowe, X_testowe, y_treningowe, y_testowe = train_test_split(X, y, test_s

# Liniowa regresja
lr = LinearRegression()
lr.fit(X_treningowe, y_treningowe)
przewidywany_y_lr = lr.predict(X_testowe)
mse_lr = mean_squared_error(y_testowe, przewidywany_y_lr)

# Regresja Ridge
ridge = Ridge(alpha=1.0)
ridge.fit(X_treningowe, y_treningowe)
y_przewidywane_ridge = ridge.predict(X_testowe)
mse_ridge = mean_squared_error(y_testowe, y_przewidywane_ridge)

# Sieć neuronowa
siec_neuronowa = MLPRegressor(hidden_layer_sizes=(10,), max_iter=1500, random_st
siec_neuronowa.fit(X_treningowe, y_treningowe)
y_przewidywane_siec_neuronowa = siec_neuronowa.predict(X_testowe)
mse_siec_neuronowa = mean_squared_error(y_testowe, y_przewidywane_siec_neuronowa

print(f"Regresja liniowa: {mse_lr}")
print(f"Regresja Ridge: {mse_ridge}")
print(f"Sieć Neuronowa: {mse_siec_neuronowa}")
```

```
Regresja liniowa: 770579.8520962859
Regresja Ridge: 770588.3407806738
Sieć Neuronowa: 993068.6666852413
```

```
C:\Users\krzys\AppData\Local\Programs\Python\Python310\lib\site-packages\sklearn
\neural_network\_multilayer_perceptron.py:691: ConvergenceWarning: Stochastic Opt
imizer: Maximum iterations (1500) reached and the optimization hasn't converged y
et.
  warnings.warn(
```

In [8]:
```
reszty = y_testowe - przewidywany_y_lr # Obliczenie reszt

# Histogram reszt
plt.figure(figsize=(8, 6))
sns.histplot(reszty, kde=True, bins=10, color='blue')
plt.title('Histogram reszt - Regresja liniowa')
plt.xlabel('Reszty')
plt.ylabel('Częstość')
plt.show()

# Wykres reszt względem przewidywanych wartości
plt.figure(figsize=(8, 6))
plt.scatter(przewidywany_y_lr, reszty, alpha=0.7, color='blue')
plt.axhline(y=0, color='red', linestyle='--')
plt.title('Wykres reszt względem przewidywanych wartości - Regresja liniowa')
plt.xlabel('Przewidywane wartości')
plt.ylabel('Reszty')
plt.show()

# Normalność reszt - wykres Q-Q
plt.figure(figsize=(8, 6))
probplot(reszty, dist="norm", plot=plt)
plt.title('Wykres Q-Q dla reszt - Regresja liniowa')
plt.show()

# Średnia kwadratowa błędu (MSE) dla modelu regresji liniowej
print(f"Mean Squared Error (MSE) dla regresji liniowej: {mse_lr:.2f}")
```

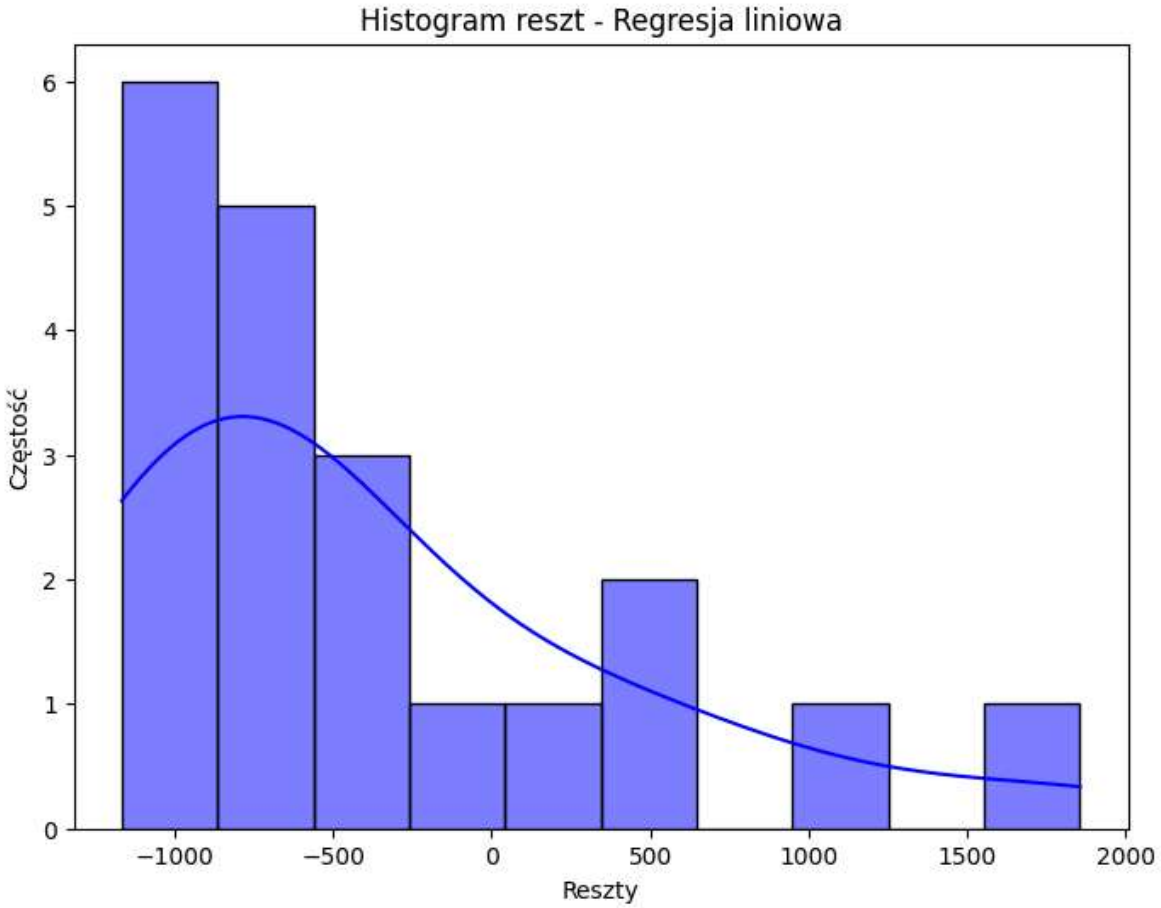
Histogram reszt - Regresja liniowa
Częstość
Reszty
0
1
2
3
4
5
6
−1000
−500
0
500
1000
1500
2000

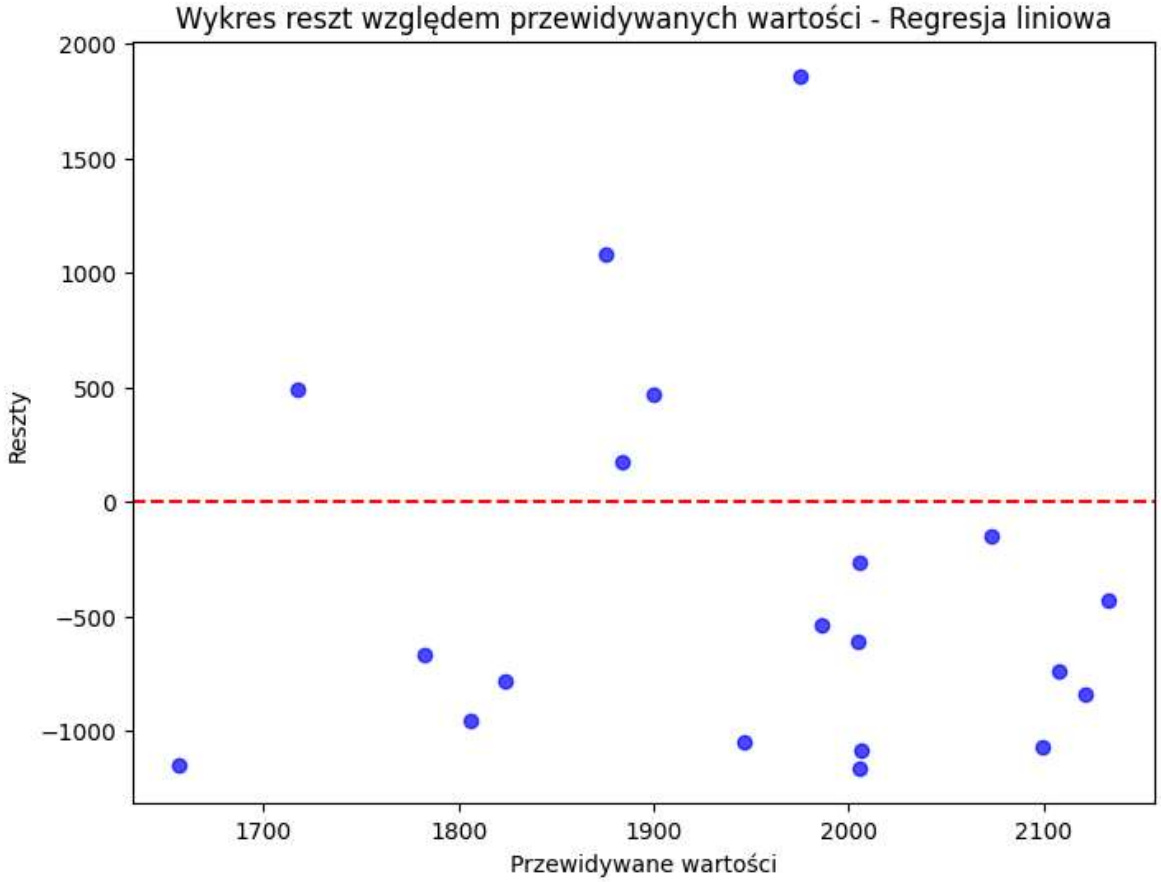
Wykres reszt względem przewidywanych wartości - Regresja liniowa
Reszty
Przewidywane wartości
2000
1500
1000
500
0
−500
−1000
1700
1800
1900
2000
2100

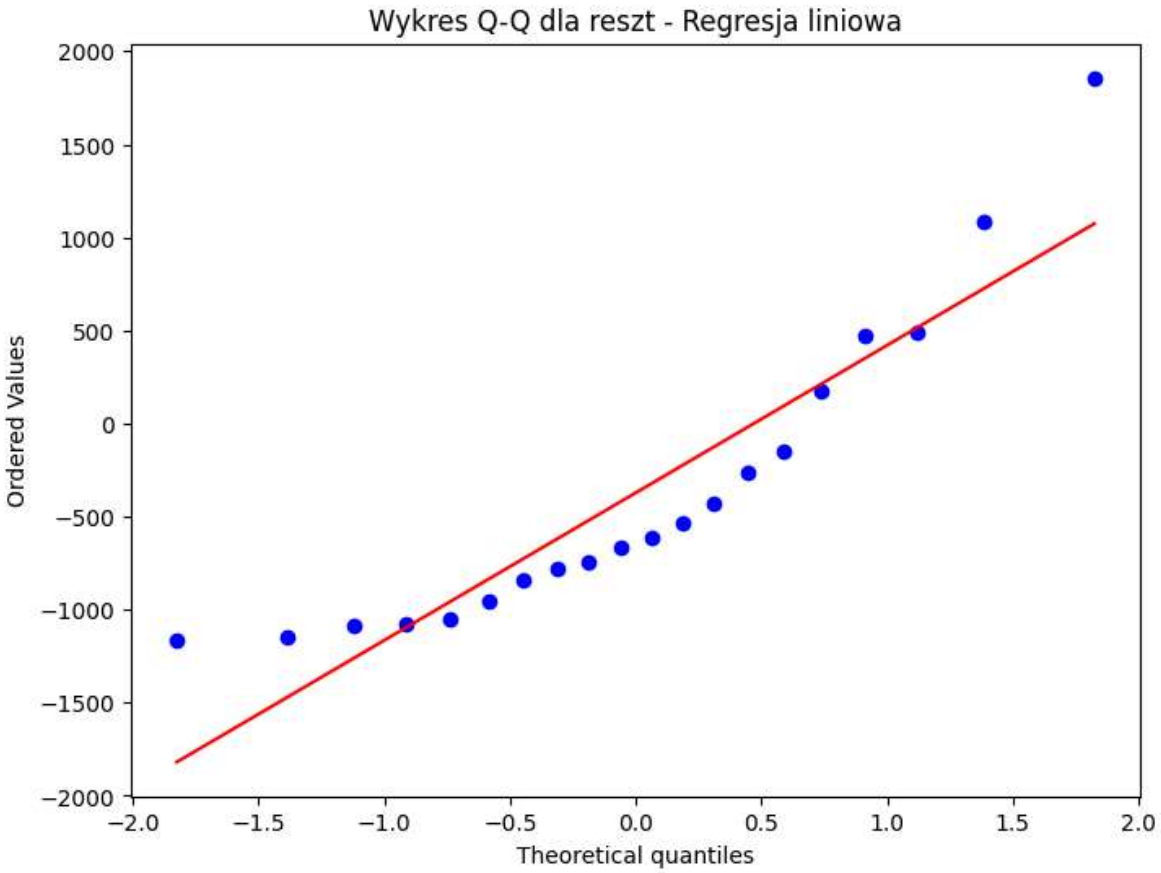


```
Mean Squared Error (MSE) dla regresji liniowej: 770579.85
```

In [9]:
```python
from statsmodels.stats.stattools import durbin_watson
from scipy.stats import shapiro

# 3.1. Sprawdzenie normalności reszt (Shapiro-Wilk)
shapiro_test_stat, shapiro_p_value = shapiro(reszty)
print("Test Shapiro-Wilka dla normalności reszt:")
print(f"Statystyka testowa: {shapiro_test_stat:.4f}, p-wartość: {shapiro_p_value

if shapiro_p_value > 0.05:
    print("Brak podstaw do odrzucenia hipotezy zerowej: reszty są normalnie rozł
else:
    print("Odrzucenie hipotezy zerowej: reszty nie są normalnie rozłożone.")

# 3.2. Test autokorelacji reszt (Durbin-Watson)
durbin_watson_stat = durbin_watson(reszty)
print("\nTest Durbin-Watson:")
print(f"Statystyka Durbin-Watson: {durbin_watson_stat:.4f}")

# Interpretacja wyników testu Durbin-Watson
if durbin_watson_stat < 1.5:
    print("Wskazanie na autokorelację dodatnią reszt.")
elif durbin_watson_stat > 2.5:
    print("Wskazanie na autokorelację ujemną reszt.")
else:
    print("Brak istotnej autokorelacji reszt.")
```

```
Test Shapiro-Wilka dla normalności reszt:
Statystyka testowa: 0.8518, p-wartość: 5.7237e-03
Odrzucenie hipotezy zerowej: reszty nie są normalnie rozłożone.

Test Durbin-Watson:
Statystyka Durbin-Watson: 1.3496
Wskazanie na autokorelację dodatnią reszt.
```

In [10]:

```python
from sklearn.preprocessing import StandardScaler
# 4. Porównaj jakość modeli przy użyciu danych o różnych skalach (np. znormalizo

# Przygotowanie danych
X = df[['age', 'income', 'savings', 'children', 'credit_score', 'spending_score'
y = df['outcome']

# Podział na zbiór treningowy i testowy
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_

# 1. Oryginalne dane
lr_orig = LinearRegression()
lr_orig.fit(X_train, y_train)
y_pred_lr_orig = lr_orig.predict(X_test)
mse_lr_orig = mean_squared_error(y_test, y_pred_lr_orig)

# 2. Znormalizowane dane
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

# Regresja Liniowa (na znormalizowanych danych)
lr_scaled = LinearRegression()
lr_scaled.fit(X_train_scaled, y_train)
y_pred_lr_scaled = lr_scaled.predict(X_test_scaled)
mse_lr_scaled = mean_squared_error(y_test, y_pred_lr_scaled)

# Regresja Ridge (na obu zbiorach)
ridge_orig = Ridge(alpha=1.0)
ridge_orig.fit(X_train, y_train)
y_pred_ridge_orig = ridge_orig.predict(X_test)
mse_ridge_orig = mean_squared_error(y_test, y_pred_ridge_orig)

ridge_scaled = Ridge(alpha=1.0)
ridge_scaled.fit(X_train_scaled, y_train)
y_pred_ridge_scaled = ridge_scaled.predict(X_test_scaled)
mse_ridge_scaled = mean_squared_error(y_test, y_pred_ridge_scaled)

# Sieć neuronowa (na obu zbiorach)
nn_orig = MLPRegressor(hidden_layer_sizes=(10,), max_iter=500, random_state=42)
nn_orig.fit(X_train, y_train)
y_pred_nn_orig = nn_orig.predict(X_test)
mse_nn_orig = mean_squared_error(y_test, y_pred_nn_orig)

nn_scaled = MLPRegressor(hidden_layer_sizes=(10,), max_iter=500, random_state=42
nn_scaled.fit(X_train_scaled, y_train)
y_pred_nn_scaled = nn_scaled.predict(X_test_scaled)
mse_nn_scaled = mean_squared_error(y_test, y_pred_nn_scaled)

# Porównanie wyników
print("Regresja Liniowa:")
print(f"- Oryginalne dane: MSE = {mse_lr_orig:.2f}")
```

```
print(f"- Znormalizowane dane: MSE = {mse_lr_scaled:.2f}")

print("\nRegresja Ridge:")
print(f"- Oryginalne dane: MSE = {mse_ridge_orig:.2f}")
print(f"- Znormalizowane dane: MSE = {mse_ridge_scaled:.2f}")

print("\nSieć Neuronowa:")
print(f"- Oryginalne dane: MSE = {mse_nn_orig:.2f}")
print(f"- Znormalizowane dane: MSE = {mse_nn_scaled:.2f}")
```

```
Regresja Liniowa:
- Oryginalne dane: MSE = 770579.85
- Znormalizowane dane: MSE = 770579.85

Regresja Ridge:
- Oryginalne dane: MSE = 770588.34
- Znormalizowane dane: MSE = 770417.22

Sieć Neuronowa:
- Oryginalne dane: MSE = 1928394.26
- Znormalizowane dane: MSE = 3079022.97
C:\Users\krzys\AppData\Local\Programs\Python\Python310\lib\site-packages\sklearn
\neural_network\_multilayer_perceptron.py:691: ConvergenceWarning: Stochastic Opt
imizer: Maximum iterations (500) reached and the optimization hasn't converged ye
t.
  warnings.warn(
C:\Users\krzys\AppData\Local\Programs\Python\Python310\lib\site-packages\sklearn
\neural_network\_multilayer_perceptron.py:691: ConvergenceWarning: Stochastic Opt
imizer: Maximum iterations (500) reached and the optimization hasn't converged ye
t.
  warnings.warn(
```

In [ ]: